

Laporan Tugas Besar Machine Learning
Analisis Pola Asosiasi antara Bahan Utama dan Bahan Tambahan Pangan pada Produk
Makanan Kemasan Menggunakan Algoritma Apriori



Disusun oleh:
Kelompok 9

ERVINA KUSNANDA	2409082
NAUFAL RIZKI	2410946
SHAKILA AULIA	2403086

PRODI ILMU KOMPUTER
FAKULTAS PENDIDIKAN MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS PENDIDIKAN INDONESIA

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	4
PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Tujuan Analisis.....	4
1.3 Ruang Lingkup.....	4
BAB II.....	5
TINJAUAN PUSTAKA.....	5
2.1 Data Mining.....	5
2.2 Association Rule Mining.....	5
2.3 Market Basket Analysis.....	6
2.4 Algoritma Apriori.....	6
2.5 Metrik Evaluasi Association Rule.....	7
2.5.1 Support.....	7
2.5.2 Confidence.....	7
2.5.3 Lift.....	8
2.5.4 Coverage.....	8
2.5.5 Conviction.....	8
BAB III.....	9
METODOLOGI PENELITIAN.....	9
3.1 Pendekatan Penelitian.....	9
3.2 Desain Eksperimen dan Variabel Penelitian.....	9
3.3 Pengumpulan Dataset.....	10
3.4 Preprocessing dan Automated Data Cleaning.....	10
3.5 Transformasi Data dan Pemodelan Apriori di R Studio.....	11
3.6 Hyperparameter Tuning dan Pemilihan Model Terbaik.....	12
3.7 Metrik Evaluasi Association Rules.....	13
3.8 Visualisasi dan Interpretasi Hasil.....	13
BAB IV.....	14
HASIL DAN PEMBAHASAN.....	14
4.1 Ringkasan Dataset Final.....	14
Berdasarkan Tabel 4.1, dataset terdiri atas 499 transaksi yang merepresentasikan produk makanan kemasan. Setelah proses harmonisasi, diperoleh 411 item unik dengan rata-rata 6,71 item pada setiap transaksi. Variasi item yang cukup tinggi menunjukkan bahwa dataset memiliki keragaman komposisi yang baik untuk proses pencarian pola asosiasi.....	14
4.2 Frekuensi BTP Target.....	14
4.3 Hasil Hyperparameter Tuning.....	15
4.4 Hasil Model Final.....	16
4.5 Top 10 Rules Final Berdasarkan Lift.....	16
4.6 Ringkasan Statistik Metrik Final.....	17
4.7 Analisis Rules Berdasarkan BTP.....	18
4.7.1 MSG.....	18
4.7.2 Pengemulsi.....	19

4.7.3 Propionat.....	19
4.7.4 Benzoat.....	19
4.8 Interpretasi Hasil.....	19
4.8 Perbandingan, Pros, dan Cons.....	20
BAB V.....	21
KESIMPULAN DAN SARAN.....	21
5.1 Kesimpulan.....	21
5.2 Saran.....	22
DAFTAR PUSTAKA.....	23

BAB I

PENDAHULUAN

1.1 Latar Belakang

Produk makanan kemasan yang beredar di pasaran mengandung berbagai bahan tambahan pangan (BTP) yang dicantumkan pada label komposisi. BTP seperti pengawet (natrium benzoat, kalium propionat), penguat rasa (MSG), dan pengemulsi berperan penting dalam menjaga kualitas dan umur simpan produk. Namun, kecenderungan kombinasi BTP tertentu dengan bahan-bahan utama belum banyak dikaji secara sistematis menggunakan pendekatan data mining.

Analisis ini memanfaatkan algoritma Apriori untuk menemukan pola asosiasi antara bahan-bahan utama produk makanan dengan keberadaan BTP tertentu. Dengan memahami pola ini, dapat diidentifikasi kombinasi bahan mana yang cenderung disertai BTP spesifik — informasi yang berguna bagi konsumen, regulator, maupun produsen dalam formulasi produk.

1.2 Tujuan Analisis

- Mengidentifikasi pola asosiasi antara bahan utama produk makanan dan BTP target (MSG, Pengemulsi, Propionat/Benzoat).
- Mengukur kekuatan asosiasi menggunakan metrik support, confidence, lift, conviction, dan coverage.
- Mengevaluasi kualitas rules yang dihasilkan oleh algoritma Apriori.
- Memberikan insight berbasis data mengenai karakteristik formulasi produk makanan kemasan.

1.3 Ruang Lingkup

Analisis ini mencakup 499 produk makanan kemasan dari berbagai kategori (roti, minuman, mi, keripik, saus, produk susu, dll). BTP yang dijadikan target analisis adalah:

- MSG (Monosodium Glutamat / Penguat Rasa)
- Pengemulsi (termasuk Lesitin Kedelai)
- Propionat (Kalsium Propionat — pengawet roti)
- Benzoat (Natrium Benzoat — pengawet minuman dan saus)

BAB II

TINJAUAN PUSTAKA

2.1 Data Mining

Data mining merupakan proses mengekstraksi informasi, pola, dan pengetahuan yang bernilai dari sekumpulan data berukuran besar. Teknik ini digunakan untuk menemukan hubungan, kecenderungan, atau pola tersembunyi yang sulit diidentifikasi secara manual. Data mining menjadi salah satu tahapan utama dalam proses Knowledge Discovery in Databases (KDD), yaitu proses memperoleh pengetahuan baru dari data yang tersedia.

Dalam berbagai bidang, data mining dimanfaatkan untuk mendukung pengambilan keputusan berdasarkan data. Penerapannya meliputi analisis perilaku konsumen, deteksi penipuan, prediksi penjualan, analisis kesehatan, hingga analisis komposisi produk makanan. Melalui proses data mining, kumpulan data yang besar dapat diolah menjadi informasi yang lebih mudah dipahami dan dimanfaatkan.

Secara umum, tahapan data mining meliputi pengumpulan data, pembersihan data (data cleaning), transformasi data, proses pemodelan, evaluasi hasil, dan interpretasi pengetahuan yang diperoleh. Pada penelitian ini, data mining digunakan untuk menemukan pola keterkaitan antara bahan utama dan bahan tambahan pangan (BTP) pada produk makanan kemasan.

2.2 Association Rule Mining

Association Rule Mining merupakan salah satu teknik data mining yang digunakan untuk menemukan hubungan atau asosiasi antar item dalam suatu kumpulan data transaksi. Teknik ini pertama kali diperkenalkan untuk menganalisis perilaku pembelian konsumen pada supermarket melalui konsep Market Basket Analysis.

Hasil dari Association Rule Mining berupa aturan asosiasi (association rules) yang menunjukkan keterkaitan antara suatu item dengan item lainnya. Bentuk umum aturan asosiasi dapat dituliskan sebagai berikut:

$$A \rightarrow B$$

di mana A disebut sebagai antecedent (sisi kiri aturan) dan B disebut sebagai consequent (sisi kanan aturan).

Pada penelitian ini, antecedent berupa kombinasi bahan utama produk makanan, sedangkan consequent berupa bahan tambahan pangan (BTP) yang menjadi target analisis, yaitu MSG, Pengemulsi, Propionat, dan Benzoat. Dengan demikian, aturan yang dihasilkan dapat menunjukkan bahan-bahan apa saja yang cenderung muncul bersamaan dengan BTP tertentu.

2.3 Market Basket Analysis

Market Basket Analysis (MBA) merupakan metode analisis yang bertujuan untuk menemukan pola keterkaitan antar item dalam suatu transaksi. Metode ini banyak digunakan dalam bidang ritel untuk mengetahui produk-produk yang sering dibeli secara bersamaan oleh konsumen.

Konsep dasar Market Basket Analysis adalah menganggap setiap transaksi sebagai sebuah keranjang (basket) yang berisi beberapa item. Dari kumpulan transaksi tersebut kemudian dicari pola kemunculan item yang sering muncul secara bersamaan. Hasil analisis biasanya dinyatakan dalam bentuk aturan asosiasi yang menggambarkan hubungan antar item.

Dalam penelitian ini, konsep Market Basket Analysis diterapkan pada data komposisi produk makanan kemasan. Setiap produk dianggap sebagai satu transaksi, sedangkan setiap bahan yang terdapat pada komposisi produk dianggap sebagai item. Dengan pendekatan ini, dapat ditemukan pola hubungan antara bahan utama dengan bahan tambahan pangan yang digunakan dalam formulasi produk makanan.

2.4 Algoritma Apriori

Algoritma Apriori merupakan salah satu algoritma paling populer dalam Association Rule Mining. Algoritma ini digunakan untuk menemukan frequent itemset, yaitu kombinasi item yang sering muncul dalam kumpulan transaksi. Frequent itemset kemudian digunakan sebagai dasar untuk membentuk association rules.

Prinsip utama Apriori adalah Apriori Property atau Anti-Monotone Property yang menyatakan bahwa apabila suatu itemset tidak memenuhi nilai minimum support, maka

seluruh superset dari itemset tersebut juga tidak akan memenuhi minimum support. Dengan prinsip ini, proses pencarian dapat dilakukan lebih efisien karena banyak kandidat itemset yang dapat dieliminasi lebih awal.

Tahapan umum algoritma Apriori meliputi:

- 1) Menghitung support setiap item tunggal.
- 2) Menentukan frequent itemset yang memenuhi minimum support.
- 3) Membentuk kandidat itemset baru dari frequent itemset sebelumnya.
- 4) Menghitung support kandidat itemset.
- 5) Mengulangi proses hingga tidak ditemukan frequent itemset baru.
- 6) Membentuk association rules berdasarkan minimum confidence yang telah ditentukan.

Pada penelitian ini, algoritma Apriori diimplementasikan menggunakan package arules pada perangkat lunak R Studio untuk menghasilkan aturan asosiasi antara bahan utama dan bahan tambahan pangan.

2.5 Metrik Evaluasi Association Rule

Kualitas association rules dievaluasi menggunakan beberapa metrik yang umum digunakan dalam Association Rule Mining, yaitu support, confidence, lift, coverage, dan conviction.

2.5.1 Support

Support menunjukkan seberapa sering suatu aturan muncul dalam keseluruhan dataset. Nilai support diperoleh dari proporsi transaksi yang mengandung antecedent dan consequent secara bersamaan terhadap total transaksi.

Nilai support yang tinggi menunjukkan bahwa aturan tersebut cukup representatif terhadap keseluruhan data.

2.5.2 Confidence

Confidence merupakan ukuran tingkat kepercayaan suatu aturan. Confidence menunjukkan probabilitas kemunculan consequent ketika antecedent muncul dalam suatu transaksi.

Semakin tinggi nilai confidence, semakin besar kemungkinan consequent muncul ketika antecedent ditemukan.

2.5.3 Lift

Lift digunakan untuk mengukur kekuatan hubungan antara antecedent dan consequent dibandingkan dengan kemunculan acak. Nilai lift lebih dari satu menunjukkan adanya hubungan positif antara kedua item.

Interpretasi nilai lift adalah sebagai berikut:

- Lift > 1 menunjukkan asosiasi positif.
- Lift $= 1$ menunjukkan tidak ada hubungan khusus.
- Lift < 1 menunjukkan asosiasi negatif.

Pada penelitian ini, lift digunakan sebagai metrik utama dalam menentukan kualitas association rules karena mampu menunjukkan kekuatan hubungan yang sebenarnya.

2.5.4 Coverage

Coverage menunjukkan proporsi transaksi yang mengandung antecedent pada suatu aturan. Metrik ini digunakan untuk mengetahui seberapa luas aturan tersebut berlaku pada dataset.

Semakin besar nilai coverage, semakin banyak transaksi yang dicakup oleh aturan tersebut.

2.5.5 Conviction

Conviction merupakan metrik yang digunakan untuk mengukur tingkat ketergantungan antara antecedent dan consequent. Nilai conviction yang tinggi menunjukkan bahwa hubungan yang terbentuk tidak terjadi secara kebetulan.

Metrik ini melengkapi interpretasi support, confidence, dan lift sehingga kualitas aturan dapat dievaluasi secara lebih komprehensif.

BAB III

METODOLOGI PENELITIAN

3.1 Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan Experimental Research Design sebagai kerangka utama. Desain ini dipilih karena proses penelitian dilakukan melalui eksperimen data, yaitu menguji beberapa kombinasi parameter algoritma Apriori untuk menemukan pola asosiasi paling kuat pada komposisi produk makanan kemasan. Tugas machine learning yang digunakan adalah unsupervised learning karena data tidak memiliki label kelas target seperti pada klasifikasi atau regresi. Model tidak memprediksi kelas, tetapi mengekstraksi pola keterkaitan antar item komposisi dalam bentuk association rules.

Dalam konteks penelitian ini, setiap produk makanan diperlakukan sebagai satu transaksi, sedangkan setiap bahan dalam daftar komposisi diperlakukan sebagai item/atribut kategorikal. Pola yang dicari adalah hubungan bahan utama pada sisi kiri aturan (LHS/antecedent) terhadap BTP target pada sisi kanan aturan (RHS/consequent). Dengan demikian, bentuk rule yang dianalisis adalah: {Bahan Utama} -> {BTP Target}.

3.2 Desain Eksperimen dan Variabel Penelitian

Penelitian ini dirancang untuk menganalisis hubungan antara bahan utama produk makanan dengan bahan tambahan pangan menggunakan algoritma Apriori.

Aspek	Penjelasan
Objek penelitian	Label komposisi produk makanan kemasan dari berbagai merek/varian.
Instance / transaction	Satu produk makanan kemasan, misalnya satu varian roti, mi, saus, minuman, atau snack.
Feature / item	Setiap bahan tunggal pada komposisi, misalnya Tepung Terigu, Air, Gula, Ragi, Margarin, MSG, Pengemulsi, Propionat, Benzoat.
Target analisis	BTP target pada RHS, yaitu MSG, Pengemulsi, Propionat, dan Benzoat.
Output model	Association rules berbentuk LHS -> RHS beserta nilai support, confidence, lift, conviction, coverage, dan count.

3.3 Pengumpulan Dataset

Data penelitian diperoleh melalui pengumpulan komposisi produk makanan kemasan yang tercantum pada label kemasan produk. Data dikumpulkan dari berbagai kategori produk pangan yang beredar di pasaran, seperti roti, mi instan, snack, saus, minuman, dan produk pangan olahan lainnya.

Setiap produk dicatat dalam bentuk daftar komposisi bahan penyusun produk. Data yang diperoleh masih berupa teks bebas sehingga memiliki variasi penulisan yang cukup tinggi, seperti penggunaan huruf kapital yang berbeda, singkatan bahan, sinonim bahan tambahan pangan, maupun keterangan tambahan yang dituliskan dalam tanda kurung.

Berbeda dengan penelitian klasifikasi atau regresi, penelitian ini tidak melakukan pembagian data menjadi data latih dan data uji karena Association Rule Mining merupakan metode unsupervised learning. Evaluasi model dilakukan berdasarkan kualitas aturan asosiasi yang dihasilkan, bukan berdasarkan akurasi prediksi terhadap label target.

3.4 Preprocessing dan Automated Data Cleaning

Sebelum dilakukan pemodelan, data terlebih dahulu melalui proses preprocessing dan pembersihan data untuk meningkatkan kualitas dataset.

Tahap	Penjelasan
Noise reduction	Menghapus whitespace berlebih, tanda kutip pembungkus, serta bagian teks yang tidak relevan.
Tokenization	Memecah teks komposisi menjadi item bahan berdasarkan pemisah koma.
Feature standardization	Menyamakan sinonim BTP, seperti penguat rasa/monosodium glutamat/mononatrium glutamat menjadi MSG.
Deduplication	Menghapus item duplikat dalam satu transaksi agar satu bahan hanya dihitung satu kali pada produk yang sama.
Basket transformation	Mengubah daftar item menjadi format transaksi yang dapat dibaca oleh package arules.

Setelah data komposisi dikumpulkan, dilakukan proses *noise reduction* untuk menghilangkan karakter yang tidak diperlukan seperti spasi berlebih dan tanda kutip pembungkus. Selanjutnya dilakukan *tokenization* untuk memisahkan komposisi produk menjadi item-item individual berdasarkan pemisah koma.

Tahap berikutnya adalah *feature standardization*, yaitu proses harmonisasi berbagai variasi penulisan bahan tambahan pangan. Sebagai contoh, istilah "penguat rasa", "monosodium glutamat", dan "mononatrium glutamat" diseragamkan menjadi "MSG". Proses ini bertujuan menghindari terpecahnya frekuensi item yang sebenarnya merepresentasikan bahan yang sama.

Selanjutnya dilakukan *deduplication* untuk memastikan setiap item hanya dihitung satu kali dalam satu transaksi. Setelah seluruh proses preprocessing selesai, data ditransformasikan ke dalam format basket transaction yang dapat diproses oleh package *arules*.

3.5 Transformasi Data dan Pemodelan Apriori di R Studio

Data hasil preprocessing kemudian dikonversi menjadi objek *transactions* menggunakan package *arules* pada R Studio. Dalam format ini, data direpresentasikan sebagai matriks biner, di mana nilai 1 menunjukkan keberadaan suatu item pada transaksi tertentu dan nilai 0 menunjukkan item tersebut tidak muncul.

Pemodelan dilakukan menggunakan algoritma Apriori untuk menemukan pola asosiasi antar item yang memenuhi nilai minimum support dan minimum confidence yang telah ditentukan.

Untuk memastikan aturan yang dihasilkan sesuai dengan tujuan penelitian, digunakan pengaturan:

```
appearance = list(  
  rhs = btp_items,  
  default = "lhs"  
)
```

Konfigurasi tersebut memaksa bahan tambahan pangan target hanya muncul pada sisi consequent (RHS), sehingga aturan yang dihasilkan berbentuk:

$\{\text{Bahan Utama}\} \rightarrow \{\text{BTP Target}\}$

Dengan pendekatan ini, penelitian berfokus pada identifikasi pola hubungan antara bahan utama dan penggunaan bahan tambahan pangan pada produk makanan kemasan.

3.6 Hyperparameter Tuning dan Pemilihan Model Terbaik

Pemodelan tidak dilakukan hanya dengan satu nilai support dan confidence. Beberapa skenario diuji untuk melihat dampak perubahan threshold terhadap jumlah rules, cakupan BTP, confidence rata-rata, dan lift rata-rata. Prinsipnya, support terlalu tinggi dapat menghilangkan BTP yang jarang muncul, sedangkan support terlalu rendah dapat menghasilkan rules yang terlalu spesifik dan kurang representatif. Confidence terlalu tinggi dapat membuat rules menjadi sedikit, sedangkan confidence terlalu rendah dapat menghasilkan hubungan yang lemah.

Pada dataset ini, skenario support = 0,050 dan confidence = 0,50 memang menghasilkan rules yang cukup kuat, tetapi terlalu ketat karena tidak mencakup seluruh BTP target. Oleh karena itu, eksperimen dilanjutkan dengan support dan confidence yang lebih fleksibel. Parameter final dipilih berdasarkan empat kriteria: seluruh BTP target tercakup, jumlah rules cukup untuk dianalisis, setiap rule memiliki lift > 1, dan minimum count tidak terlalu kecil.

Supp	Conf	Min Count	Rules Final	BTP Covered	Avg Conf	Avg Lift	Top Lift
0.050	0.50	25	9	3	0.6137	2.9511	5.5069
0.020	0.30	10	105	4	0.6164	4.3332	15.5938
0.010	0.30	5	211	4	0.6793	4.0205	15.5938
0.005	0.20	3	390	4	0.6839	4.1210	17.8214
0.005	0.50	3	295	4	0.7955	4.5901	17.8214
0.003	0.05	2	571	4	0.6972	4.2263	17.8214

Berdasarkan tabel eksperimen, parameter final yang dipilih adalah minimum support = 0,020 dan minimum confidence = 0,30. Skenario ini menghasilkan 105 rules setelah pruning, mencakup seluruh BTP target, memiliki minimum count sekitar 10 transaksi, dan tetap menghasilkan lift tertinggi sebesar 15,5938. Skenario ini lebih seimbang dibanding support 0,050 yang terlalu ketat dan support 0,005 yang menghasilkan terlalu banyak rules serta lebih rentan terhadap pola dengan count kecil.

Gambar 2. Perbandingan jumlah rules setelah pruning pada beberapa skenario support-confidence.

3.7 Metrik Evaluasi Association Rules

Kualitas aturan asosiasi dievaluasi menggunakan metrik yang umum digunakan pada Association Rule Mining. Berbeda dengan tugas klasifikasi, evaluasi tidak menggunakan accuracy, precision, recall, maupun confusion matrix karena penelitian ini tidak menghasilkan prediksi kelas.

Metrik	Rumus	Fungsi
Support	$\text{count}(A \cup B) / N$	Mengukur seberapa sering kombinasi LHS dan RHS muncul pada seluruh transaksi.
Confidence	$\text{count}(A \cup B) / \text{count}(A)$	Mengukur peluang RHS muncul ketika LHS muncul.
Lift	$\text{confidence}(A \rightarrow B) / \text{support}(B)$	Mengukur kekuatan hubungan dibandingkan kemunculan acak. Lift > 1 berarti asosiasi positif.
Coverage	$\text{support} / \text{confidence}$	Mengukur proporsi transaksi yang memuat LHS.
Conviction	$(1 - \text{support}(B)) / (1 - \text{confidence})$	Mengukur kekuatan dependensi arah aturan.
Count	jumlah transaksi $A \cup B$	Mengontrol agar rule tidak hanya berasal dari transaksi yang sangat sedikit.

Rule terbaik dipilih dengan prioritas lift tertinggi, tetapi tetap memperhatikan confidence, support, conviction, coverage, dan count. Dengan demikian, rule yang dipresentasikan bukan hanya rule yang kuat secara rasio, tetapi juga cukup representatif terhadap dataset.

3.8 Visualisasi dan Interpretasi Hasil

Hasil Association Rule Mining divisualisasikan menggunakan package arulesViz dan ggplot2 pada R Studio. Visualisasi digunakan untuk mempermudah interpretasi pola hubungan antar item yang ditemukan.

Visualisasi yang digunakan meliputi:

- Item Frequency Plot untuk menampilkan item yang paling sering muncul.
- Scatter Plot untuk menunjukkan hubungan antara support, confidence, dan lift.
- Grouped Matrix Plot untuk melihat keterkaitan antar item dalam bentuk matriks.
- Network Graph untuk menggambarkan hubungan antar item dalam bentuk jaringan.
- Bar Chart Top Rules untuk menampilkan aturan dengan nilai lift tertinggi.

Dari seluruh visualisasi yang digunakan, network graph dipilih sebagai visual utama karena mampu menunjukkan hubungan antara bahan utama dan bahan tambahan pangan secara intuitif dan mudah dipahami.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Ringkasan Dataset Final

Setelah melalui proses preprocessing, harmonisasi bahan tambahan pangan (BTP), dan transformasi ke dalam format transaksi, diperoleh dataset final yang siap digunakan untuk proses Association Rule Mining menggunakan algoritma Apriori.

Tabel 4.1 Ringkasan Dataset Final

Komponen	Nilai
Jumlah transaksi	499
Jumlah item unik setelah harmonisasi BTP	411
Rata-rata item per transaksi	6.71
Minimum item per transaksi	1
Maksimum item per transaksi	12

Berdasarkan Tabel 4.1, dataset terdiri atas 499 transaksi yang merepresentasikan produk makanan kemasan. Setelah proses harmonisasi, diperoleh 411 item unik dengan rata-rata 6,71 item pada setiap transaksi. Variasi item yang cukup tinggi menunjukkan bahwa dataset memiliki keragaman komposisi yang baik untuk proses pencarian pola asosiasi.


4.2 Frekuensi BTP Target

Sebelum dilakukan pemodelan, dilakukan analisis frekuensi terhadap empat BTP target yang menjadi fokus penelitian, yaitu MSG, Pengemulsi, Propionat, dan Benzoat.

Tabel 4.2 Frekuensi BTP Target

BTP	Count	Support
MSG	144	0.2886
Pengemulsi	104	0.2084
Propionat	28	0.0561
Benzoat	53	0.1062

Berdasarkan Tabel 4.2, MSG merupakan BTP dengan frekuensi tertinggi, yaitu muncul pada 144 transaksi atau sekitar 28,86% dari keseluruhan dataset. Pengemulsi muncul pada 104 transaksi (20,84%), sedangkan Benzoat dan Propionat memiliki frekuensi yang lebih rendah. Rendahnya frekuensi Propionat menunjukkan bahwa penggunaan nilai minimum support yang terlalu tinggi berpotensi menghilangkan pola asosiasi yang berkaitan dengan BTP tersebut.



Gambar 4.1 Frekuensi BTP Target pada Dataset

4.3 Hasil Hyperparameter Tuning


Untuk memperoleh model yang menghasilkan association rules yang kuat dan representatif, dilakukan serangkaian eksperimen menggunakan beberapa kombinasi nilai minimum support dan minimum confidence.

Tabel 4.3 Hasil Hyperparameter Tuning

Supp	Conf	Min Count	Rules Final	BTP Covered	Avg Conf	Avg Lift	Top Lift
0.050	0.50	25	9	3	0.6137	2.9511	5.5069
0.020	0.30	10	105	4	0.6164	4.3332	15.5938
0.010	0.30	5	211	4	0.6793	4.0205	15.5938
0.005	0.20	3	390	4	0.6839	4.1210	17.8214
0.005	0.50	3	295	4	0.7955	4.5901	17.8214
0.003	0.05	2	571	4	0.6972	4.2263	17.8214

Hasil eksperimen menunjukkan bahwa semakin kecil nilai support yang digunakan, semakin banyak association rules yang dihasilkan. Namun jumlah rules yang terlalu besar berpotensi menghasilkan pola yang kurang representatif karena didukung oleh jumlah transaksi yang relatif kecil.

Berdasarkan hasil tersebut, dipilih kombinasi minimum support sebesar 0,020 dan minimum confidence sebesar 0,30 karena mampu mencakup seluruh BTP target, menghasilkan jumlah rules yang masih dapat dianalisis secara efektif, serta memiliki nilai lift maksimum yang tinggi.



4.4 Hasil Model Final

Model Apriori final dibangun menggunakan parameter minimum support sebesar 0,020 dan minimum confidence sebesar 0,30.

Tabel 4.4 Ringkasan Model Final

Komponen	Nilai
Minimum support final	0,020 (2%)
Minimum confidence final	0,30 (30%)
Minimum count per rule	10
Rules lift > 1 sebelum pruning	266
Rules final setelah pruning redundant	105
BTP target tercakup	MSG, Pengemulsi, Propionat, Benzoat

Hasil eksperimen menunjukkan bahwa semakin kecil nilai support yang digunakan, semakin banyak association rules yang dihasilkan. Namun jumlah rules yang terlalu besar berpotensi menghasilkan pola yang kurang representatif karena didukung oleh jumlah transaksi yang relatif kecil.

Berdasarkan hasil tersebut, dipilih kombinasi minimum support sebesar 0,020 dan minimum confidence sebesar 0,30 karena mampu mencakup seluruh BTP target, menghasilkan jumlah rules yang masih dapat dianalisis secara efektif, serta memiliki nilai lift maksimum yang tinggi.


4.5 Top 10 Rules Final Berdasarkan Lift

Sepuluh rules dengan nilai lift tertinggi ditampilkan pada Tabel 4.5.

Tabel 4.5 Top 10 Association Rules Berdasarkan Lift

No	LHS (Bahan Utama)	RHS (BTP)	Support	Confidence	Lift	Conviction	Coverage	Count
1	Air, Ragi	Propionat	0.0421	0.8750	15.5938	7.5511	0.0481	21
2	Margarin, Ragi	Propionat	0.0341	0.8500	15.1482	6.2926	0.0401	17
3	Air, Tepung Terigu	Propionat	0.0441	0.8462	15.0797	6.1353	0.0521	22
4	Air, Margarin	Propionat	0.0301	0.8333	14.8512	5.6633	0.0361	15
5	Ragi	Propionat	0.0461	0.7419	13.2224	3.6576	0.0621	23
6	Garam, Margarin, Tepung Terigu	Propionat	0.0281	0.7368	13.1316	3.5868	0.0381	14
7	Margarin, Tepung Terigu	Propionat	0.0341	0.7083	12.6235	3.2362	0.0481	17
8	Garam, Margarin	Propionat	0.0281	0.7000	12.4750	3.1463	0.0401	14
9	Margarin	Propionat	0.0341	0.6800	12.1186	2.9496	0.0501	17
10	Gula, Pati Modifikasi	Benzoat	0.0301	0.9375	8.8267	14.3006	0.0321	15

Dari sepuluh rules dengan nilai lift tertinggi, sembilan rules memiliki consequent berupa Propionat. Temuan ini menunjukkan bahwa penggunaan Propionat cenderung sangat spesifik pada kombinasi bahan tertentu dibandingkan BTP lainnya.



Gambar 4.3 Top 10 Rules Berdasarkan Nilai Lift


4.6 Ringkasan Statistik Metrik Final

Untuk mengevaluasi kualitas rules yang dihasilkan, dilakukan analisis terhadap distribusi nilai support, confidence, lift, dan conviction.

Metrik	Min	Q1	Median	Mean	Max	Inf_count
Support	0.0200	0.0240	0.0301	0.0420	0.2505	0
Confidence	0.3012	0.5000	0.6000	0.6164	1.0000	0
Lift	1.3908	2.6402	3.2320	4.3332	15.5938	0
Conviction	1.1357	1.5753	1.9862	3.0038	17.0741	4

Rata-rata nilai lift sebesar 4,3332 menunjukkan bahwa rules yang dihasilkan memiliki asosiasi positif yang jauh lebih kuat dibandingkan kemunculan secara acak. Selain itu, median confidence sebesar 0,6000 menunjukkan bahwa sebagian besar aturan mampu menjelaskan kemunculan consequent dengan tingkat kepercayaan sekitar 60%.

Nilai conviction maksimum sebesar 17,0741 menunjukkan adanya beberapa aturan dengan tingkat dependensi yang sangat kuat antara antecedent dan consequent.



Gambar 4.4 Scatter Plot Support, Confidence, dan Lift

4.7 Analisis Rules Berdasarkan BTP

BTP	Jumlah Rules	Lift Min	Lift Max	Lift Mean	Confidence Mean
MSG	22	1.3908	3.4653	2.6313	0.7593
Pengemulsi	44	1.4540	3.6557	2.7424	0.5716
Propionat	10	5.3747	15.5938	12.9619	0.7273
Benzoat	29	2.8359	8.8267	5.0627	0.5377

4.7.1 MSG

MSG menghasilkan 22 association rules dengan rata-rata confidence sebesar 0,7593 dan rata-rata lift sebesar 2,6313. Rules yang terbentuk umumnya berkaitan dengan bahan-bahan yang banyak digunakan pada produk gurih, seperti bumbu, minyak nabati, tepung tapioka, dan garam. Nilai

lift yang relatif moderat menunjukkan bahwa MSG digunakan pada berbagai kategori produk sehingga asosiasinya tidak terlalu spesifik.

4.7.2 Pengemulsi

Pengemulsi menghasilkan 44 association rules dengan rata-rata lift sebesar 2,7424. Jumlah rules yang cukup besar menunjukkan bahwa Pengemulsi digunakan pada berbagai jenis produk olahan. Karena frekuensi kemunculannya cukup tinggi, nilai lift yang dihasilkan cenderung lebih moderat dibandingkan Propionat.

4.7.3 Propionat

Propionat menghasilkan nilai lift rata-rata tertinggi, yaitu 12,9619. Rule dengan lift tertinggi adalah {Air, Ragi} → {Propionat} dengan lift sebesar 15,5938 dan confidence sebesar 0,8750. Temuan ini menunjukkan bahwa produk yang mengandung kombinasi air dan ragi memiliki peluang jauh lebih besar untuk menggunakan Propionat dibandingkan produk secara umum. Pola ini sesuai dengan karakteristik produk bakery yang memanfaatkan Propionat sebagai bahan pengawet.

4.7.4 Benzoat

Benzoat menghasilkan 29 association rules dengan rata-rata lift sebesar 5,0627. Rules yang terbentuk banyak melibatkan bahan seperti gula, pati modifikasi, cabai, air, dan pengatur keasaman. Pola tersebut menunjukkan karakteristik produk saus, minuman, dan produk berbasis cairan yang umumnya memanfaatkan Benzoat sebagai bahan pengawet.

Propionat memiliki lift rata-rata paling tinggi karena kemunculannya lebih spesifik pada kombinasi bahan tertentu, terutama bahan yang berkaitan dengan produk bakeri. Benzoat memiliki asosiasi kuat pada bahan-bahan seperti air, gula, cabai, pengatur keasaman, dan pati modifikasi. MSG dan Pengemulsi memiliki jumlah rules yang lebih banyak, tetapi lift rata-ratanya lebih rendah karena frekuensi kemunculannya lebih luas pada berbagai kategori produk.

4.8 Interpretasi Hasil


Propionat: Rules Propionat memiliki lift tertinggi, misalnya {Air, Ragi} → {Propionat} dengan lift 15,5938 dan confidence 0,8750. Artinya, produk yang memiliki kombinasi air dan ragi jauh lebih mungkin mengandung Propionat dibandingkan produk secara umum. Pola ini relevan dengan karakteristik produk bakeri.

Benzoat: Benzoat muncul kuat pada pola bahan seperti gula, pati modifikasi, cabai, air, dan pengatur keasaman. Ini mengarah pada karakteristik produk saus, minuman, atau produk berair/asam yang membutuhkan pengawet.

MSG: MSG memiliki rules yang berkaitan dengan produk gurih, seperti bumbu, garam, minyak nabati, tepung tapioka, atau bahan snack/mi. Lift MSG lebih rendah daripada Propionat karena MSG muncul pada kategori produk yang lebih luas.

Pengemulsi: Pengemulsi memiliki jumlah rules cukup besar karena digunakan pada berbagai produk olahan. Nilai lift-nya cenderung moderat karena base support Pengemulsi lebih tinggi sehingga peluang kemunculan acaknya juga lebih besar.

Network Graph Top 10 Association Rules Final



Gambar 4.5 Network Graph Top Rules

4.8 Perbandingan, Pros, dan Cons

Aspek	Penjelasan
Kelebihan	Association Rules mudah diinterpretasikan karena hasilnya berbentuk aturan LHS -> RHS.
Kelebihan	Apriori efektif untuk menemukan pola tersembunyi pada data transaksi tanpa label kelas.
Kelebihan	Metrik lift membantu membedakan hubungan yang benar-benar lebih kuat dari kemunculan acak.
Keterbatasan	Hasil sangat bergantung pada pemilihan support dan confidence.
Keterbatasan	Lift tinggi dapat muncul pada rule dengan count kecil, sehingga perlu dikontrol dengan minimum support/count.
Keterbatasan	Association rules menunjukkan asosiasi, bukan hubungan sebab-akibat.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penerapan Association Rule Mining menggunakan algoritma Apriori pada dataset komposisi 499 produk makanan kemasan, diperoleh beberapa kesimpulan sebagai berikut.

1. Penelitian berhasil mengidentifikasi pola asosiasi antara bahan utama dan bahan tambahan pangan (BTP) pada produk makanan kemasan menggunakan pendekatan Market Basket Analysis. Setelah proses preprocessing dan harmonisasi data, diperoleh 411 item unik yang dianalisis dalam bentuk transaksi menggunakan package arules pada R Studio.
2. Hasil eksperimen menunjukkan bahwa pemilihan nilai minimum support dan minimum confidence berpengaruh terhadap jumlah rules yang dihasilkan. Berdasarkan proses hyperparameter tuning, kombinasi minimum support sebesar 0,020 dan minimum confidence sebesar 0,30 dipilih sebagai parameter terbaik karena mampu mencakup seluruh BTP target (MSG, Pengemulsi, Propionat, dan Benzoat) dengan jumlah rules yang masih representatif untuk dianalisis.
3. Model final menghasilkan 105 association rules setelah proses pruning redundant rules. Seluruh rules yang dipertahankan memiliki nilai lift lebih besar dari satu, sehingga menunjukkan adanya asosiasi positif antara antecedent dan consequent.
4. BTP Propionat memiliki asosiasi paling kuat dibandingkan BTP lainnya. Rule dengan nilai lift tertinggi adalah {Air, Ragi} $\rightarrow$ {Propionat} dengan support sebesar 0,0421, confidence sebesar 0,8750, dan lift sebesar 15,5938. Hasil ini menunjukkan bahwa produk yang mengandung kombinasi air dan ragi memiliki peluang yang jauh lebih besar untuk menggunakan Propionat dibandingkan rata-rata produk dalam dataset.
5. MSG dan Pengemulsi menghasilkan jumlah rules yang lebih banyak dibandingkan Propionat, namun memiliki nilai lift rata-rata yang lebih rendah. Hal ini menunjukkan bahwa kedua BTP tersebut digunakan pada berbagai kategori produk sehingga pola penggunaannya lebih umum dan tidak terlalu spesifik.
6. Benzoat menunjukkan pola asosiasi yang kuat dengan bahan-bahan seperti gula, pati modifikasi, cabai, air, dan pengatur keasaman. Temuan ini mengindikasikan bahwa Benzoat banyak digunakan pada produk saus, minuman, dan produk berbasis cairan yang memerlukan pengawetan.

7. Secara keseluruhan, algoritma Apriori terbukti mampu menemukan pola formulasi tersembunyi pada komposisi produk makanan kemasan dan memberikan wawasan mengenai karakteristik penggunaan bahan tambahan pangan berdasarkan kombinasi bahan utama yang digunakan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diberikan untuk penelitian selanjutnya adalah sebagai berikut.

1. Menambah jumlah data produk makanan kemasan agar pola asosiasi yang diperoleh menjadi lebih representatif dan mampu menggambarkan kondisi pasar secara lebih luas.
2. Memperluas cakupan bahan tambahan pangan yang dianalisis, tidak hanya terbatas pada MSG, Pengemulsi, Propionat, dan Benzoat, tetapi juga mencakup pewarna, pemanis buatan, antioksidan, pengatur keasaman, dan kelompok BTP lainnya.
3. Mengelompokkan produk berdasarkan kategori makanan, seperti snack, minuman, mi instan, bakery, dan frozen food sebelum dilakukan proses Association Rule Mining. Pendekatan ini berpotensi menghasilkan pola formulasi yang lebih spesifik untuk setiap kategori produk.
4. Membandingkan performa algoritma Apriori dengan algoritma Association Rule Mining lainnya, seperti FP-Growth atau Eclat, untuk melihat efisiensi dan kualitas rules yang dihasilkan.
5. Mengembangkan visualisasi interaktif berbasis dashboard sehingga hasil Association Rule Mining dapat dieksplorasi dengan lebih mudah oleh pengguna.

DAFTAR PUSTAKA

- Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, 487–499.
- Han, J., Kamber, M., & Pei, J. (2022). *Data mining: Concepts and techniques* (4th ed.). Morgan Kaufmann.
- Hahsler, M., Grün, B., & Hornik, K. (2005). arules—A computational environment for mining association rules and frequent item sets. *Journal of Statistical Software*, 14(15), 1–25.
- Hahsler, M. (2023). *Introduction to arules: Mining association rules and frequent itemsets with R*. CRAN Project.
- Larose, D. T., & Larose, C. D. (2014). *Discovering knowledge in data: An introduction to data mining* (2nd ed.). Wiley.
- Tan, P. N., Steinbach, M., Karpatne, A., & Kumar, V. (2019). *Introduction to data mining* (2nd ed.). Pearson.

LAMPIRAN

Lampiran kode Program R

```
cat("\n=====\\n")
cat(" MODEL FINAL APRIORI\\n")
cat("=====\\n")
cat("Support final      :", FINAL_SUPPORT, "\\n")
cat("Confidence final   :", FINAL_CONFIDENCE, "\\n")
cat("Total rules final:", length(rules_final), "\\n")

cat("\n=====\\n")
cat(" TOP 10 RULES FINAL - SORTED BY LIFT\\n")
cat("=====\\n")
inspect(top10)

# TABEL EVALUASI QUALITY METRICS
q <- as.data.frame(quality(top10))

# Coverage = P(LHS)
q$coverage <- round(q$support / q$confidence, 4)

# Support RHS bisa diturunkan dari confidence / lift
support_rhs <- q$confidence / q$lift

# Conviction = (1 - Support(RHS)) / (1 - Confidence)
q$conviction <- ifelse(
  q$confidence >= 1,
  Inf,
  round((1 - support_rhs) / (1 - q$confidence), 4)
)

q$support <- round(q$support, 4)
q$confidence <- round(q$confidence, 4)
q$lift <- round(q$lift, 4)
q$count <- as.integer(q$count)

cat("\n=====\\n")
cat(" QUALITY METRICS TOP 10 RULES\\n")
cat("=====\\n")
print(q[, c("support", "confidence", "lift", "coverage", "conviction", "count")])
..
```